

LAPORAN TEKNIS MACHINE LEARNING
KLASIFIKASI KELAYAKAN PENERIMA BEASISWA MENGGUNAKAN
DATA MINING



Dosen Pengampu :
Abu Salam, M.Kom.

Dibuat Oleh :
Rafania Putri Mahendra (A11.2024.15609)

PRODI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO
SEMARANG

2026

DAFTAR ISI

DAFTAR ISI.....	ii
DAFTAR GAMBAR.....	iv
DAFTAR TABEL	iv
BAB I PENDAHULUAN.....	6
1.1 Latar Belakang	6
1.2 Rumusan Masalah	7
1.3 Tujuan Penelitian	7
1.4 Manfaat Penelitian	7
BAB II METODOLOGI.....	9
2.1 Metode Penelitian	9
2.2 Dataset Penelitian.....	10
2.3 Business Understanding.....	11
2.4 Data Understanding	12
2.5 Data Preparation.....	13
2.6 Modeling	15
2.6.1 Random Forest	15
2.6.2 Support Vector Machine (SVM).....	16
2.6.3 Extreme Gradient Boosting (XGBoost).....	16
BAB III HASIL DAN ANALISIS.....	17
3.1 Hasil Pelatihan Model.....	17
3.2 Evaluasi Model	17
3.2.1 Confusion Matrix Random Forest	17
3.2.2 Confusion Matrix Support Vector Machine	18
3.2.3 Confusion Matrix XGBoost.....	19
3.2.4 ROC Curve.....	20
3.3 Interpretasi Model Menggunakan SHAP	20
3.4 Implementasi Aplikasi Streamlit.....	21
3.4.1 Halaman Dashboard EDA.....	22
3.4.2 Halaman Model Demo (Prediksi Kelayakan)	23
3.4.3 Halaman Evaluasi Model.....	25

3.4.4	Halaman Interpretasi Hasil	26
3.4.5	Halaman Dokumentasi.....	28
3.5	Analisis Hasil	29
3.5.1	Analisis Performa Model	29
3.5.2	Analisis Faktor yang Mempengaruhi Prediksi.....	29
3.5.3	Analisis Implementasi Aplikasi	30
BAB IV KESIMPULAN DAN REKOMENDASI		31
4.1	Kesimpulan	31
4.2	Rekomendasi.....	31
DAFTAR PUSTAKA.....		32

DAFTAR GAMBAR

Gambar 2.1 Alur Penelitian	10
Gambar 2.2 Histogram Distribusi Setiap Variabel pada Dataset.....	12
Gambar 2.3 Heatmap Korelasi Antar Variabel.....	13
Gambar 2.4 Flowchart Data Preparation	14
Gambar 3.1 Confusion Matrix Random Forest.....	18
Gambar 3.2 Confusion Matrix Support Vector Machine.....	18
Gambar 3.3 Confusion Matrix XGBoost.....	19
Gambar 3.4 ROC Curve Ketiga Algoritma.....	20
Gambar 3.5 SHAP Summary Plot	21
Gambar 3.6 Dashboard Exploratory Data Analysis (EDA).....	23
Gambar 3.7 Halaman Model Demo	24
Gambar 3.8 Halaman Evaluasi Model	26
Gambar 3.9 Halaman Interpretasi Hasil.....	27
Gambar 3.10 Halaman Dokumentasi.....	28

DAFTAR TABEL

Tabel 2.1 Deskripsi Variabel Dataset	11
Tabel 2.2 Hasil Label Encoding.....	14
Tabel 2.3 Parameter Model.....	15
Tabel 3.1 Hasil Perbandingan Akurasi Model.....	17

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi pada era digital telah mendorong pemanfaatan *Artificial Intelligence* (AI) dalam berbagai bidang, termasuk pendidikan. Salah satu cabang AI yang berkembang pesat adalah *Machine Learning*, yaitu teknologi yang mampu mempelajari pola dari data untuk menghasilkan prediksi atau keputusan secara otomatis. Penerapan *Machine Learning* telah digunakan pada berbagai sektor, seperti kesehatan, keuangan, industri, dan pendidikan karena mampu meningkatkan efisiensi, akurasi, serta objektivitas dalam proses pengambilan keputusan (Trisnawan & Susilawati, 2025).

Dalam dunia pendidikan tinggi, salah satu proses yang memerlukan ketelitian adalah seleksi penerima beasiswa. Penentuan penerima beasiswa umumnya mempertimbangkan berbagai aspek, seperti prestasi akademik, kondisi ekonomi, keaktifan organisasi, dan faktor pendukung lainnya. Seiring meningkatnya jumlah pendaftar setiap tahun, proses seleksi secara manual menjadi semakin kompleks, memerlukan waktu yang lebih lama, serta berpotensi menimbulkan inkonsistensi dalam penilaian.

Machine Learning dapat dimanfaatkan sebagai sistem pendukung keputusan untuk membantu proses seleksi beasiswa secara lebih cepat dan berbasis data. Melalui pembelajaran dari data historis penerima beasiswa, model klasifikasi mampu mengenali pola hubungan antara karakteristik mahasiswa dengan status penerimaan beasiswa. Hasil prediksi yang dihasilkan tidak dimaksudkan untuk menggantikan pengambil keputusan, melainkan menjadi rekomendasi yang dapat meningkatkan objektivitas dan efisiensi proses seleksi.

Penelitian ini menggunakan *dataset* penerima beasiswa yang terdiri atas 300 data mahasiswa dengan delapan atribut, yaitu IPK, semester, penghasilan orang tua, jumlah tanggungan keluarga, prestasi, keaktifan organisasi, status rumah, dan jenis kelamin. Tiga algoritma klasifikasi yang dibandingkan adalah Random Forest, Support Vector Machine (SVM), dan Extreme Gradient Boosting (XGBoost). Berdasarkan hasil pengujian, algoritma Random Forest memperoleh akurasi sebesar 73,33%, lebih tinggi dibandingkan SVM sebesar 70,00% dan XGBoost sebesar 68,33%, sehingga dipilih sebagai model terbaik.

Selain membangun model klasifikasi, penelitian ini juga menerapkan metode SHAP (SHapley Additive Explanations) untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi sehingga model menjadi lebih transparan dan mudah dipahami. Model terbaik kemudian diimplementasikan ke dalam aplikasi berbasis Streamlit agar pengguna dapat melakukan prediksi kelayakan penerima beasiswa melalui antarmuka yang sederhana. Melalui penelitian ini diharapkan proses seleksi beasiswa dapat dilakukan secara lebih efektif, efisien, objektif, serta menjadi referensi penerapan *Machine Learning* dalam pengembangan sistem pendukung keputusan di bidang pendidikan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana membangun model *Machine Learning* untuk melakukan klasifikasi kelayakan penerima beasiswa berdasarkan data akademik dan nonakademik mahasiswa?
2. Bagaimana performa algoritma Random Forest, Support Vector Machine (SVM), dan XGBoost dalam melakukan klasifikasi penerima beasiswa?
3. Algoritma manakah yang memberikan performa terbaik berdasarkan hasil evaluasi menggunakan metrik akurasi?
4. Bagaimana metode SHAP dapat digunakan untuk menginterpretasikan hasil prediksi model *Machine Learning*?

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Membangun model *Machine Learning* yang mampu melakukan prediksi kelayakan penerima beasiswa berdasarkan data mahasiswa.
2. Membandingkan performa algoritma Random Forest, Support Vector Machine (SVM), dan XGBoost.
3. Menentukan algoritma terbaik berdasarkan hasil evaluasi model.
4. Menginterpretasikan hasil prediksi menggunakan metode SHAP sehingga model menjadi lebih mudah dipahami.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

1. Bagi Perguruan Tinggi
Memberikan alternatif sistem pendukung keputusan dalam proses seleksi penerima beasiswa sehingga proses penilaian dapat dilakukan secara lebih cepat, objektif, dan konsisten.
2. Bagi Mahasiswa
Memberikan gambaran mengenai faktor-faktor yang memengaruhi peluang memperoleh beasiswa sehingga mahasiswa dapat memahami aspek yang perlu ditingkatkan.

3. Bagi Peneliti
Menambah pengalaman dalam menerapkan metode *Machine Learning*, interpretasi model menggunakan SHAP, serta pengembangan aplikasi berbasis Streamlit.
4. Bagi Penelitian Selanjutnya
Menjadi referensi dalam pengembangan penelitian mengenai sistem klasifikasi maupun sistem pendukung keputusan berbasis *Machine Learning* pada bidang pendidikan.


BAB II METODOLOGI

2.1 Metode Penelitian

Penelitian ini menggunakan metode CRISP-DM (*Cross Industry Standard Process for Data Mining*) sebagai kerangka kerja dalam proses pengembangan model *Machine Learning*. Metode CRISP-DM dipilih karena memiliki tahapan yang sistematis, fleksibel, dan banyak digunakan dalam penelitian maupun implementasi proyek berbasis data (Ardhi Baskara et al., 2025). Melalui metode ini, setiap proses mulai dari identifikasi permasalahan hingga implementasi model dilakukan secara terstruktur sehingga menghasilkan model yang lebih optimal dan mudah dievaluasi.

CRISP-DM terdiri atas enam tahapan utama, yaitu *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, dan *Deployment* (Raihani & Dwitama, 2025). Keenam tahapan tersebut saling berkaitan sehingga hasil dari suatu tahapan dapat digunakan sebagai dasar dalam proses berikutnya. Apabila pada tahap evaluasi ditemukan bahwa model belum memenuhi performa yang diharapkan, maka proses dapat kembali ke tahap sebelumnya untuk dilakukan perbaikan.

Pada penelitian ini, setiap tahapan CRISP-DM diterapkan secara berurutan untuk menghasilkan model klasifikasi penerima beasiswa. *Dataset* yang digunakan diproses terlebih dahulu melalui tahap *preprocessing*, kemudian dilakukan pelatihan menggunakan tiga algoritma klasifikasi, yaitu Random Forest, Support Vector Machine (SVM), dan Extreme Gradient Boosting (XGBoost). Model dengan performa terbaik selanjutnya diimplementasikan ke dalam aplikasi berbasis web menggunakan Streamlit sehingga dapat digunakan sebagai media prediksi penerima beasiswa.



Gambar 2.1 Alur Penelitian

2.2 Dataset Penelitian

Dataset yang digunakan dalam penelitian ini diperoleh dari *platform* Kaggle, yaitu *dataset* “*Dataset Seleksi Beasiswa - Tugas Machine Learning*” yang dapat diakses melalui tautan berikut: <https://www.kaggle.com/datasets/mustapas2/dataset-seleksi-beasiswa-tugas-ml>. *Dataset* ini terdiri atas 300 data mahasiswa yang setiap datanya merepresentasikan informasi akademik dan nonakademik yang digunakan sebagai dasar dalam menentukan kelayakan penerima beasiswa. *Dataset* ini memiliki 8 atribut prediktor dan 1 atribut target, yaitu status penerimaan beasiswa. Sebelum digunakan dalam proses pemodelan, *dataset* diperiksa untuk memastikan tidak terdapat nilai yang hilang (*missing value*), data duplikat, maupun inkonsistensi format data. Selanjutnya, atribut kategorikal diubah menjadi bentuk numerik menggunakan teknik *label encoding* agar dapat diproses oleh algoritma *Machine Learning*. Deskripsi setiap variabel yang digunakan dalam penelitian ini disajikan pada Tabel 2.1.

Tabel 2.1 Deskripsi Variabel Dataset

No.	Variabel	Tipe Data	Keterangan
1.	IPK	Numeric	Nilai rata-rata akademik mahasiswa
2.	Semester	Numeric	Semester yang sedang ditempuh mahasiswa
3.	Penghasilan Orang Tua	Numeric	Pendapatan orang tua per bulan
4.	Tanggungan Keluarga	Numeric	Jumlah anggota keluarga yang menjadi tanggungan orang tua
5.	Prestasi	Categorical	Tingkat prestasi akademik/non-akademik mahasiswa (contoh: kabupaten, provinsi, nasional, atau internasional)
6.	Status Keaktifan Organisasi	Categorical	Menunjukkan apakah mahasiswa aktif atau tidak dalam organisasi
7.	Status Rumah	Categorical	Kondisi kepemilikan tempat tinggal (contoh: milik sendiri atau sewa)
8.	Jenis Kelamin	Categorical	Jenis kelamin mahasiswa (P/L)
9.	Status Beasiswa	Categorical	Status kelayakan penerima beasiswa (Layak/Tidak Layak)

2.3 Business Understanding


Tahap *Business Understanding* merupakan tahapan awal dalam metodologi CRISP-DM yang bertujuan untuk memahami permasalahan, kebutuhan, serta tujuan penelitian sebelum proses pengolahan data dilakukan. Pada penelitian ini, permasalahan yang diidentifikasi adalah proses seleksi penerima beasiswa yang masih melibatkan banyak kriteria penilaian, seperti prestasi akademik, kondisi ekonomi, jumlah tanggungan keluarga, dan keaktifan organisasi. Banyaknya aspek yang harus dipertimbangkan menyebabkan proses seleksi menjadi lebih kompleks serta membutuhkan waktu yang cukup lama apabila dilakukan secara manual. Selain itu, proses penilaian juga berpotensi menghasilkan keputusan yang kurang konsisten ketika jumlah pendaftar semakin meningkat.

Berdasarkan permasalahan tersebut, penelitian ini memanfaatkan *Machine Learning* sebagai sistem pendukung keputusan untuk membantu proses klasifikasi calon penerima beasiswa berdasarkan data historis yang tersedia. Pada tahap ini juga ditentukan ruang lingkup penelitian, yaitu membangun dan membandingkan performa beberapa algoritma klasifikasi guna memperoleh model dengan kinerja terbaik, kemudian mengimplementasikan model tersebut ke dalam aplikasi berbasis web menggunakan Streamlit. Dengan adanya tahapan *Business Understanding*, proses penelitian memiliki arah yang jelas sehingga setiap tahapan dalam metodologi CRISP-DM dapat dilakukan secara sistematis dan sesuai dengan tujuan yang telah ditetapkan.

2.4 Data Understanding


Tahap *Data Understanding* dilakukan untuk memahami karakteristik dataset yang akan digunakan pada proses pemodelan *Machine Learning* melalui eksplorasi data (*Exploratory Data Analysis/EDA*) (Amalia Maresti et al., 2024). Analisis ini bertujuan untuk mengetahui struktur dataset, distribusi atribut, serta hubungan antarvariabel guna memperoleh gambaran awal dalam menentukan langkah persiapan data yang tepat. Pada penelitian ini, dataset yang digunakan terdiri atas 300 data mahasiswa dengan 1 atribut target (status penerimaan beasiswa) dan 8 atribut prediktor, meliputi IPK, Semester, Penghasilan Orang Tua, Tanggungan Keluarga, Prestasi, Aktif Organisasi, Status Rumah, dan Jenis Kelamin. Seluruh atribut tersebut dipilih karena mampu merepresentasikan aspek akademik maupun sosial ekonomi yang menjadi pertimbangan utama dalam seleksi beasiswa.

Berdasarkan hasil visualisasi, setiap atribut menunjukkan karakteristik distribusi yang berbeda dan terbagi menjadi dua tipe data. Atribut IPK, Semester, Penghasilan Orang Tua, dan Jumlah Tanggungan merupakan data numerik, sedangkan Prestasi, Aktif Organisasi, Status Rumah, dan Jenis Kelamin merupakan data kategorikal yang nantinya akan ditransformasikan ke bentuk numerik pada tahap *Data Preparation*. Visualisasi detail mengenai distribusi dari masing-masing karakteristik atribut tersebut ditunjukkan pada Gambar 2.2.



Gambar 2.2 Histogram Distribusi Setiap Variabel pada Dataset

Selain melihat distribusi data, dilakukan pula analisis korelasi menggunakan matriks korelasi (*correlation heatmap*) untuk mengetahui hubungan antar variabel. Berdasarkan hasil visualisasi terlihat bahwa sebagian besar atribut memiliki tingkat korelasi yang rendah hingga sedang sehingga setiap fitur memberikan informasi yang berbeda terhadap proses klasifikasi. Tidak ditemukannya korelasi yang sangat tinggi juga menunjukkan bahwa risiko multikolinearitas pada dataset relatif kecil sehingga seluruh atribut tetap digunakan dalam proses pelatihan model. Hasil analisis korelasi ditunjukkan pada Gambar 2.3.



Gambar 2.3 Heatmap Korelasi Antar Variabel

2.5 Data Preparation

Tahap Data Preparation dilakukan untuk mempersiapkan dataset agar dapat digunakan pada proses pelatihan model Machine Learning. Tahapan ini meliputi pemeriksaan kualitas data, transformasi atribut kategorikal menjadi bentuk numerik, serta pembagian dataset menjadi data latih dan data uji. Berdasarkan hasil pemeriksaan, dataset tidak memiliki nilai kosong (*missing value*) maupun data duplikat sehingga seluruh data dapat langsung digunakan pada tahap berikutnya tanpa memerlukan proses pembersihan tambahan.

Selanjutnya dilakukan proses *Label Encoding* pada seluruh atribut kategorikal sehingga data berbentuk teks dapat direpresentasikan dalam bentuk numerik (Rustiyana et al., 2025). Setelah proses transformasi selesai, dataset dipisahkan menjadi variabel fitur (*feature*) dan variabel target (*target*), kemudian dibagi menjadi data latih sebesar 80% dan data uji

sebesar 20% menggunakan fungsi `train_test_split()` dengan nilai `random_state = 42`. Alur proses Data Preparation ditunjukkan pada Gambar 2.4.



Gambar 2.4 Flowchart Data Preparation

Berdasarkan Gambar 2.4, proses *Data Preparation* diawali dengan pemeriksaan kualitas data untuk memastikan *dataset* tidak memiliki nilai kosong maupun data duplikat. Selanjutnya dilakukan proses *Label Encoding* terhadap atribut kategorikal agar seluruh fitur dapat diproses oleh algoritma *Machine Learning*. Tahap terakhir adalah membagi *dataset* menjadi data latih dan data uji sehingga model dapat dievaluasi menggunakan data yang belum pernah digunakan selama proses pelatihan. Sebelum proses pemodelan dilakukan, *dataset* dibagi menjadi data latih dan data uji dengan perbandingan 80:20. Pembagian ini bertujuan agar model dapat dilatih menggunakan sebagian besar data dan dievaluasi menggunakan data yang belum pernah dipelajari sebelumnya. Selain melakukan pembagian dataset, atribut kategorikal juga ditransformasikan menggunakan metode *Label Encoding*. Proses ini bertujuan mengubah data kategorikal menjadi representasi numerik sehingga dapat diproses oleh algoritma Machine Learning. Hasil transformasi setiap atribut ditunjukkan pada Tabel 2.2.

Tabel 2.2 Hasil Label Encoding

Atribut	Kategori	Nilai Encoding
Prestasi	Internasional	0
	Kabupaten	1
	Nasional	2
	Provinsi	3
	Tidak Ada	4
Aktif Organisasi	Tidak	0
	Ya	1
Status Rumah	Kontrak	0
	Kos/Asrama	1
	Menumpang	2
	Milik Sendiri	3
Jenis Kelamin	L	0
	P	1

Berdasarkan Tabel 2.2, seluruh atribut kategorikal telah berhasil dikonversi menjadi bentuk numerik sehingga seluruh fitur memiliki format yang sesuai untuk diproses oleh algoritma klasifikasi. Nilai encoding yang diberikan hanya berfungsi sebagai representasi kategori dan tidak menunjukkan adanya tingkatan atau bobot tertentu pada masing-masing kategori.

2.6 Modeling

Tahap Modeling merupakan proses membangun model Machine Learning berdasarkan dataset yang telah melalui tahap Data Preparation. Pada penelitian ini digunakan tiga algoritma klasifikasi, yaitu Random Forest, Support Vector Machine (SVM), dan Extreme Gradient Boosting (XGBoost). Ketiga algoritma dipilih karena memiliki karakteristik yang berbeda dalam melakukan proses klasifikasi sehingga dapat dibandingkan performanya untuk memperoleh model terbaik dalam memprediksi kelayakan penerima beasiswa.

Setiap algoritma dilatih menggunakan data latih yang telah dipersiapkan pada tahap sebelumnya, kemudian diuji menggunakan data uji untuk mengetahui kemampuan model dalam mengklasifikasikan data yang belum pernah dipelajari. Proses pelatihan dilakukan menggunakan pustaka Scikit-learn untuk algoritma Random Forest dan Support Vector Machine, sedangkan algoritma XGBoost diimplementasikan menggunakan pustaka XGBoost. Parameter yang digunakan pada masing-masing algoritma ditunjukkan pada Tabel 2.5.

Tabel 2.3 Parameter Model

Algoritma	Parameter	Nilai
Random Forest	n_estimators	100
	random_state	42
Support Vector Machine	kernel	rbf
	C	1.0
	gamma	scale
XGBoost	objective	binary:logistic
	random_state	42
	eval_metric	logloss

2.6.1 Random Forest

Random Forest merupakan algoritma berbasis *ensemble learning* yang bekerja dengan membangun sejumlah pohon keputusan (*decision tree*) secara acak, kemudian menggabungkan hasil prediksi setiap pohon melalui mekanisme *majority voting* (Laila Sari et al., 2026). Pendekatan ini mampu meningkatkan akurasi klasifikasi sekaligus mengurangi risiko *overfitting* yang sering terjadi pada satu pohon keputusan. Pada penelitian ini, Random Forest dilatih menggunakan data latih dengan parameter `n_estimators = 100` dan `random_state = 42`. Setelah proses pelatihan selesai, model digunakan untuk melakukan prediksi terhadap data uji. Hasil prediksi kemudian dibandingkan dengan data aktual untuk menghitung nilai akurasi serta metrik evaluasi lainnya. Berdasarkan hasil pengujian, algoritma Random Forest memberikan performa terbaik dibandingkan algoritma lain sehingga dipilih sebagai model utama pada aplikasi prediksi penerima beasiswa.

2.6.2 Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan algoritma klasifikasi yang bekerja dengan mencari *hyperplane* optimal untuk memisahkan data ke dalam dua kelas. Algoritma ini memiliki kemampuan yang baik dalam menangani data berdimensi tinggi serta mampu menghasilkan batas keputusan (*decision boundary*) yang optimal dengan memaksimalkan jarak (*margin*) antar kelas (Eldo et al., 2024). Dalam penelitian ini digunakan kernel Radial Basis Function (RBF) dengan parameter bawaan (*default*) dari Scikit-learn. Model SVM dilatih menggunakan data latih yang sama dengan algoritma lainnya sehingga hasil evaluasi dapat dibandingkan secara adil. Setelah proses pelatihan selesai, model digunakan untuk memprediksi data uji dan menghasilkan nilai akurasi sebesar 70,00%, sehingga performanya masih berada di bawah algoritma Random Forest.

2.6.3 Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) merupakan algoritma *boosting* yang membangun model secara bertahap dengan memperbaiki kesalahan pada model sebelumnya. Algoritma ini dikenal memiliki performa yang tinggi pada berbagai kasus klasifikasi karena mampu mengoptimalkan proses pembelajaran menggunakan teknik *gradient boosting* yang efisien (Firmansyah et al., n.d.). Pada penelitian ini, XGBoost dilatih menggunakan fungsi objektif `binary:logistic` dengan `eval_metric = logloss` dan `random_state = 42`. Sama seperti algoritma lainnya, proses pelatihan dilakukan menggunakan data latih dan selanjutnya diuji pada data uji. Berdasarkan hasil evaluasi, XGBoost memperoleh nilai akurasi sebesar 68,33%, sehingga performanya lebih rendah dibandingkan Random Forest maupun Support Vector Machine pada dataset penerima beasiswa yang digunakan.

BAB III

HASIL DAN ANALISIS

3.1 Hasil Pelatihan Model

Tahap pelatihan dilakukan menggunakan tiga algoritma klasifikasi dengan dataset yang telah dipersiapkan pada tahap sebelumnya. Seluruh algoritma dilatih menggunakan data latih sebanyak 240 data dan diuji menggunakan 60 data uji. Performa model kemudian diukur menggunakan metrik accuracy sehingga dapat diketahui algoritma yang memiliki kemampuan klasifikasi terbaik. Hasil pengujian menunjukkan bahwa setiap algoritma menghasilkan tingkat akurasi yang berbeda. Perbandingan hasil pengujian ketiga model disajikan pada Tabel 3.1.

Tabel 3.1 Hasil Perbandingan Akurasi Model


Algoritma	Accuracy
Random Forest	73,33%
Support Vector Machine	70,00%
XGBoost	68,33%

Berdasarkan Tabel 3.1, algoritma Random Forest memperoleh nilai akurasi tertinggi sebesar 73,33%, diikuti oleh Support Vector Machine sebesar 70,00%, sedangkan XGBoost memperoleh nilai akurasi 68,33%. Hasil tersebut menunjukkan bahwa Random Forest memiliki kemampuan yang lebih baik dalam mengenali pola data pada dataset penerima beasiswa sehingga dipilih sebagai model terbaik untuk diimplementasikan pada aplikasi prediksi.

3.2 Evaluasi Model

Pada penelitian ini, evaluasi model tidak hanya dilakukan menggunakan nilai akurasi, tetapi juga melalui visualisasi Confusion Matrix dan ROC Curve. Kedua metode tersebut digunakan untuk mengetahui kemampuan model dalam membedakan kelas penerima dan bukan penerima beasiswa secara lebih rinci.


3.2.1 Confusion Matrix Random Forest



Gambar 3.1 Confusion Matrix Random Forest

Berdasarkan Gambar 3.1, sebagian besar data berhasil diklasifikasikan dengan benar oleh model Random Forest. Jumlah prediksi yang sesuai dengan kondisi sebenarnya lebih banyak dibandingkan prediksi yang salah, sehingga menghasilkan tingkat akurasi tertinggi di antara ketiga algoritma yang diuji.


3.2.2 Confusion Matrix Support Vector Machine



Gambar 3.2 Confusion Matrix Support Vector Machine

Berdasarkan Gambar 3.2, algoritma Support Vector Machine mampu mengklasifikasikan sebagian besar data dengan baik, namun masih terdapat beberapa kesalahan klasifikasi pada kedua kelas. Hal tersebut menyebabkan nilai akurasi yang diperoleh lebih rendah dibandingkan Random Forest.


3.2.3 Confusion Matrix XGBoost



Gambar 3.3 Confusion Matrix XGBoost

Berdasarkan Gambar 3.3, algoritma XGBoost masih menghasilkan sejumlah kesalahan klasifikasi yang lebih banyak dibandingkan dua algoritma lainnya. Kondisi tersebut berdampak pada nilai akurasi yang lebih rendah sehingga model ini tidak dipilih sebagai model utama.

3.2.4 ROC Curve




Gambar 3.4 ROC Curve Ketiga Algoritma

Kurva ROC digunakan untuk mengevaluasi kemampuan model dalam membedakan kelas positif dan negatif pada berbagai nilai threshold. Berdasarkan Gambar 3.4, Random Forest menghasilkan kurva yang paling mendekati sudut kiri atas sehingga menunjukkan kemampuan klasifikasi yang lebih baik dibandingkan Support Vector Machine maupun XGBoost.

3.3 Interpretasi Model Menggunakan SHAP

Tahap interpretasi model dilakukan menggunakan metode SHAP (SHapley Additive Explanations) untuk mengetahui kontribusi setiap fitur terhadap hasil prediksi. Interpretasi model diperlukan agar keputusan yang dihasilkan oleh algoritma tidak hanya memberikan hasil klasifikasi, tetapi juga dapat dijelaskan kepada pengguna.




Gambar 3.5 SHAP Summary Plot

Berdasarkan Gambar 3.5, fitur IPK memberikan kontribusi terbesar terhadap proses prediksi penerima beasiswa. Selain itu, atribut Penghasilan Orang Tua, Prestasi, dan Tanggungan Keluarga juga memiliki pengaruh yang cukup besar dalam menentukan hasil klasifikasi. Sementara itu, atribut Jenis Kelamin dan Status Rumah memberikan kontribusi yang relatif lebih kecil dibandingkan fitur lainnya.

3.4 Implementasi Aplikasi Streamlit

Tahap implementasi dilakukan dengan mengintegrasikan model Machine Learning terbaik, yaitu Random Forest, ke dalam aplikasi berbasis web menggunakan framework Streamlit. Aplikasi dirancang sebagai sistem pendukung keputusan yang dapat membantu proses seleksi penerima beasiswa melalui antarmuka yang sederhana dan mudah digunakan. Selain fitur prediksi, aplikasi juga menyediakan dashboard analisis data, evaluasi model, interpretasi hasil, serta dokumentasi penelitian sehingga pengguna dapat memahami keseluruhan proses pengembangan sistem.

3.4.1 Halaman Dashboard EDA






Menu Utama

Navigasi Halaman:


- ☒ Dashboard EDA
- ☐ Model Dasar
- ☐ Evaluasi Model
- ☐ Interpretasi Hasil
- ☐ Dokumentasi

Aplikasi Machine Learning ini dibuat untuk memenuhi Tugas Akhir (IAIS).

Distribusi IPK Berdasarkan Status Beasiswa



Cuplikan Dataset



Gambar 3.6 Dashboard Exploratory Data Analysis (EDA)

Dashboard Exploratory Data Analysis (EDA) digunakan untuk memberikan gambaran awal mengenai karakteristik dataset yang digunakan dalam penelitian. Pada halaman ini ditampilkan informasi jumlah data, jumlah fitur, distribusi target penerima beasiswa, visualisasi korelasi antar atribut, distribusi nilai IPK berdasarkan status penerimaan beasiswa, serta cuplikan dataset. Seluruh visualisasi disajikan secara interaktif menggunakan library Plotly sehingga memudahkan pengguna dalam memahami kondisi data sebelum proses pemodelan dilakukan. Dashboard ini juga berfungsi sebagai media analisis awal untuk mengetahui pola-pola yang terdapat pada dataset. Informasi seperti proporsi mahasiswa yang diterima maupun ditolak, hubungan antar variabel, serta distribusi setiap atribut dapat digunakan sebagai dasar dalam proses Data Understanding dan Data Preparation pada metodologi CRISP-DM.

3.4.2 Halaman Model Demo (Prediksi Kelayakan)

Model Demo (Prediksi Kelayakan)

Silakan masukkan data mahasiswa pada form di bawah ini untuk mendapatkan prediksi dari model Random Forest.

Data Akademik & Ekonomi

IPK (Skala 4.00)

3.70

Semester Saat Ini

1

Penghasilan Orang Tua (Rp)

2.000.000

Jumlah Tanggungan Keluarga

3

Data Non-Akademik

Tingkat Prestasi Tertinggi

Internasional

AKMT Berprestasi/T

Tidak

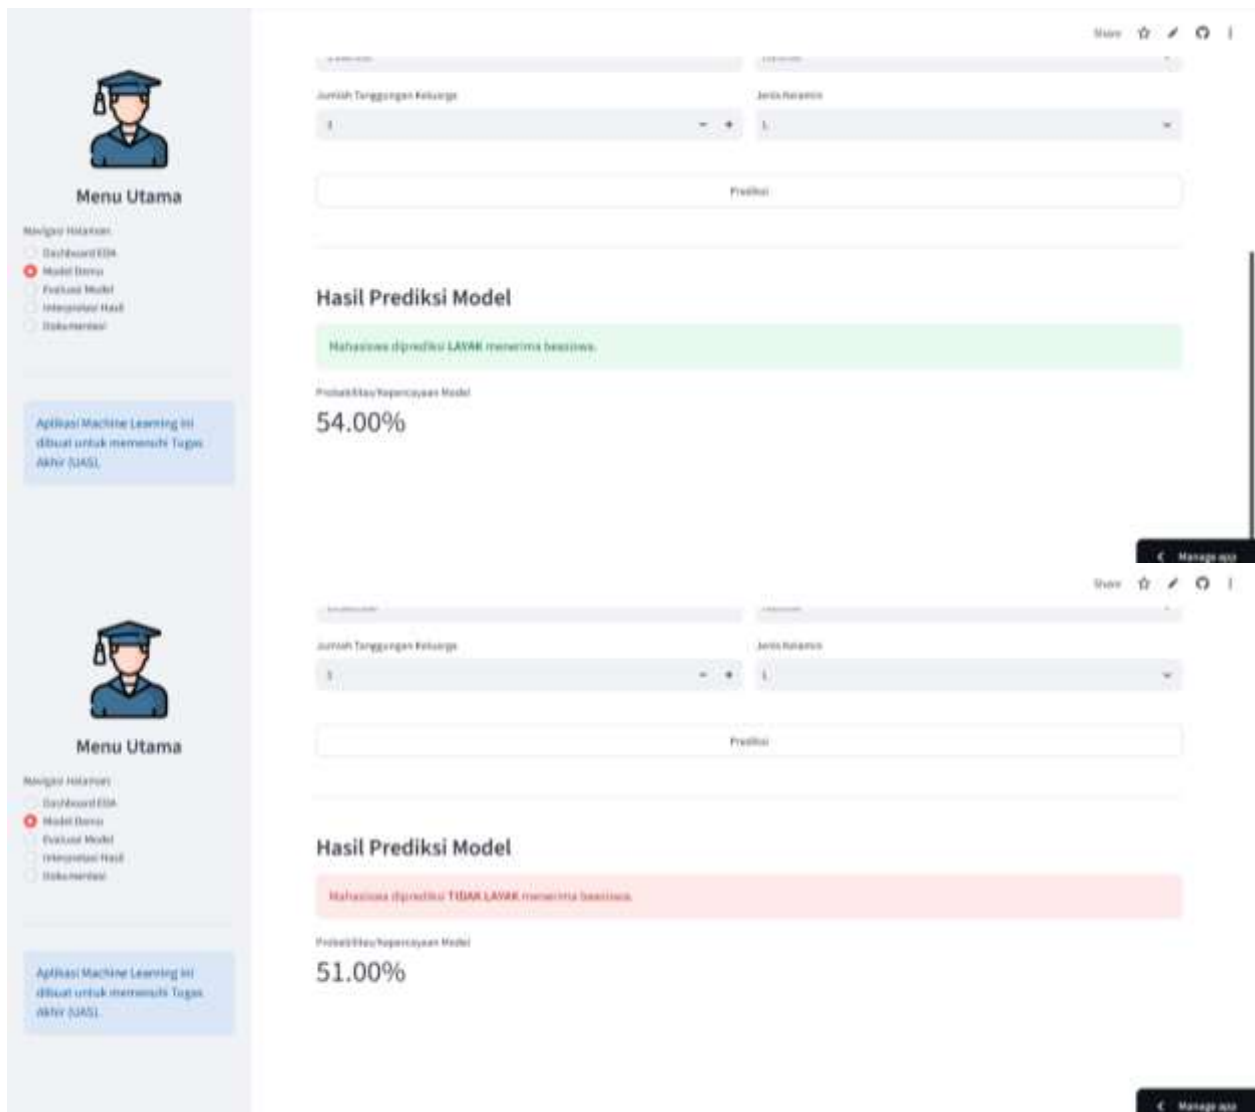
Status Kependidikan Terakhir Terakhir

Kontak

Jenis Kelamin

L


Prediksi



Gambar 3.7 Halaman Model Demo

Halaman Model Demo merupakan fitur utama pada aplikasi yang digunakan untuk melakukan prediksi kelayakan penerima beasiswa. Pengguna diminta mengisi data akademik dan non-akademik mahasiswa, meliputi IPK, semester, penghasilan orang tua, jumlah tanggungan keluarga, prestasi, keaktifan organisasi, status rumah, dan jenis kelamin. Data tersebut kemudian diproses oleh model Random Forest yang telah dilatih sebelumnya. Antarmuka dibuat sederhana sehingga pengguna hanya perlu memasukkan data sesuai kondisi mahasiswa. Setelah seluruh data diisi, pengguna dapat menekan tombol **Prediksi** untuk memperoleh hasil klasifikasi secara otomatis.

3.4.3 Halaman Evaluasi Model




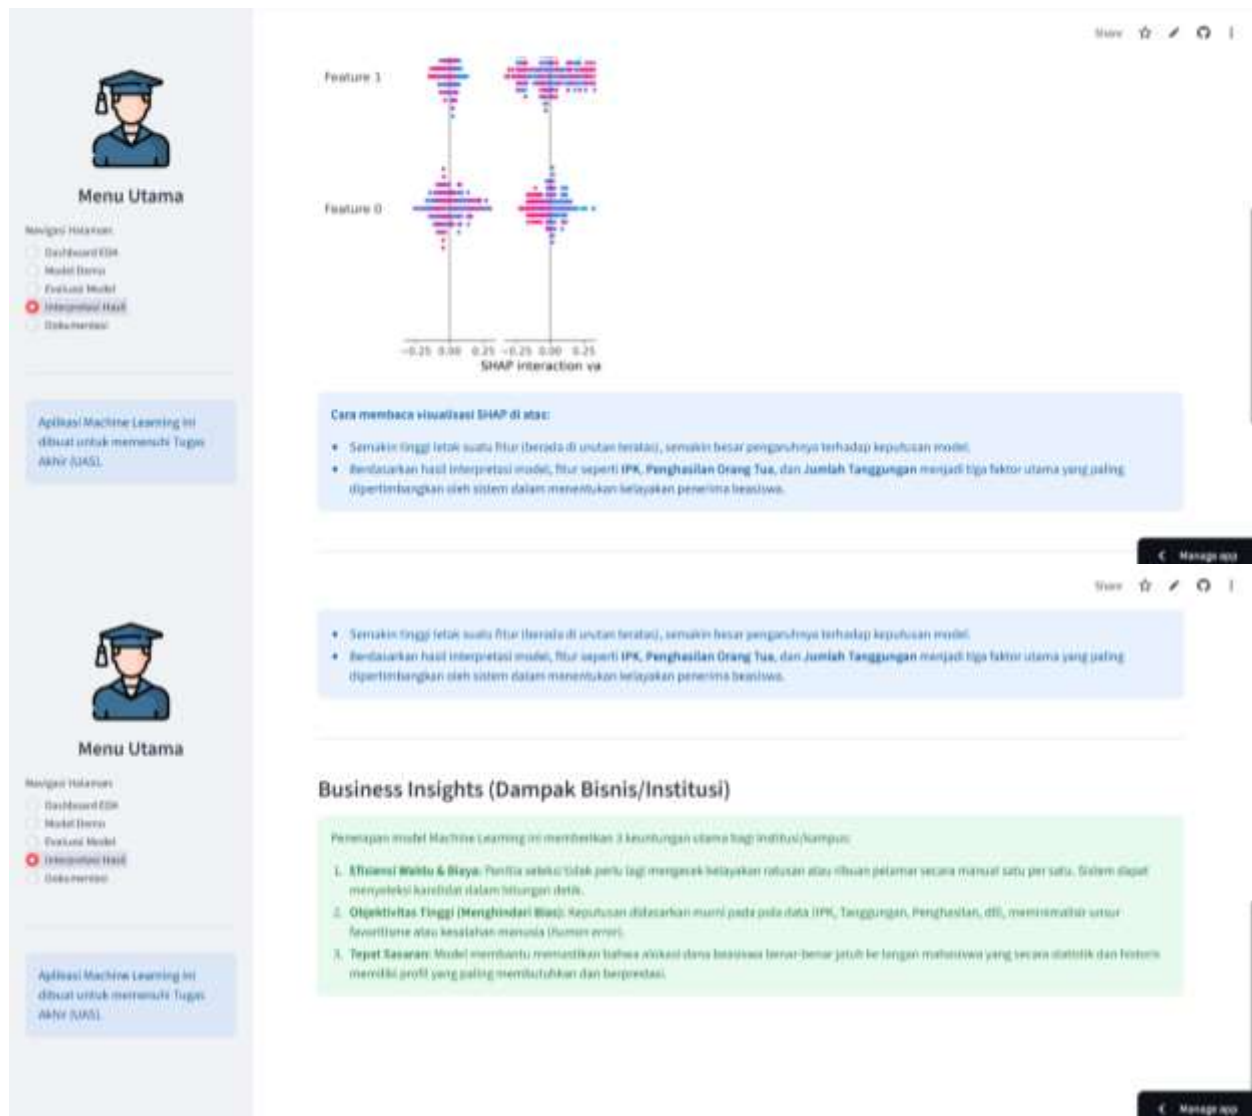


Gambar 3.8 Halaman Evaluasi Model

Halaman Evaluasi Model digunakan untuk menampilkan hasil pengujian performa model Machine Learning. Halaman ini menyajikan metrik evaluasi berupa Accuracy, Precision, Recall, dan F1-Score untuk algoritma Random Forest, Support Vector Machine (SVM), dan XGBoost. Selain itu, ditampilkan pula Confusion Matrix, ROC Curve, serta tabel perbandingan performa ketiga algoritma sehingga pengguna dapat mengetahui model dengan tingkat akurasi terbaik.

3.4.4 Halaman Interpretasi Hasil

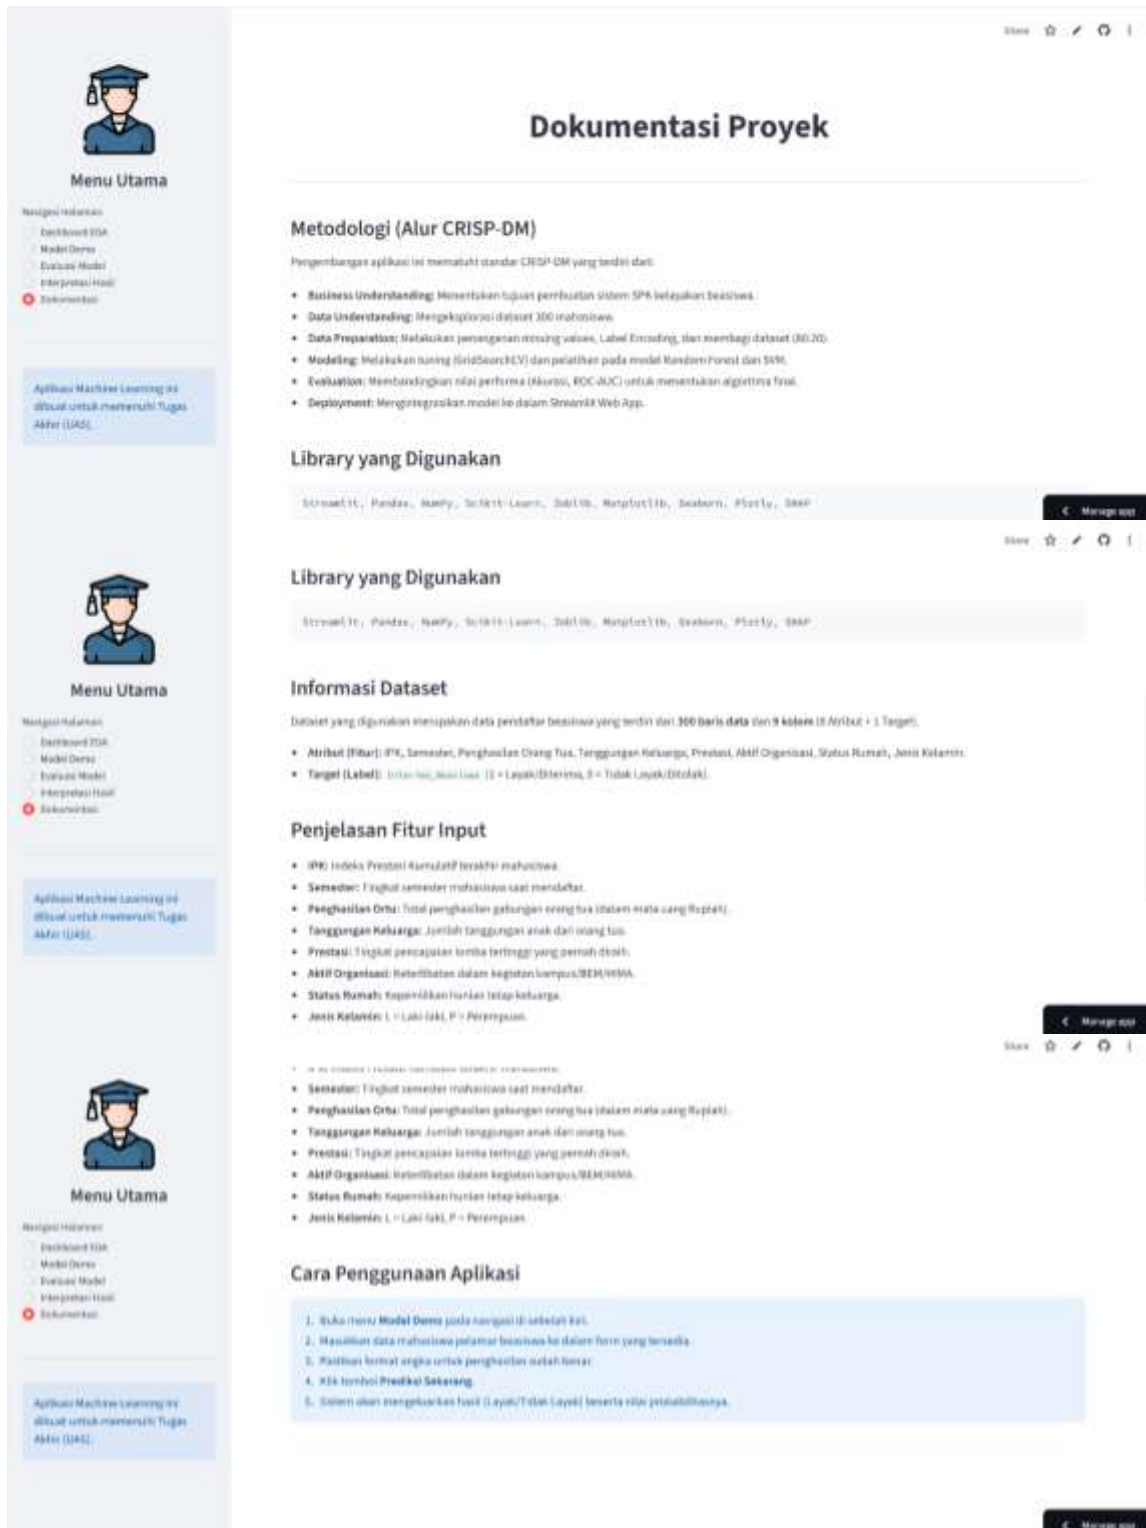




Gambar 3.9 Halaman Interpretasi Hasil

Halaman Interpretasi Hasil digunakan untuk menjelaskan proses pengambilan keputusan yang dilakukan oleh model Random Forest. Halaman ini menampilkan visualisasi SHAP Summary Plot yang menunjukkan tingkat pengaruh setiap fitur terhadap hasil prediksi. Selain itu, disajikan pula penjelasan mengenai manfaat implementasi model bagi proses seleksi beasiswa sehingga hasil prediksi dapat dipahami secara lebih transparan.

3.4.5 Halaman Dokumentasi



Gambar 3.10 Halaman Dokumentasi

Halaman Dokumentasi berisi informasi mengenai pengembangan aplikasi prediksi kelayakan penerima beasiswa. Halaman ini menyajikan ringkasan metodologi CRISP-DM,

library yang digunakan, informasi dataset, deskripsi setiap atribut, serta panduan penggunaan aplikasi. Informasi tersebut bertujuan untuk membantu pengguna memahami cara kerja aplikasi dan proses prediksi yang dilakukan oleh sistem.

3.5 Analisis Hasil

Penelitian ini menghasilkan sebuah model Machine Learning untuk memprediksi kelayakan penerima beasiswa menggunakan tiga algoritma klasifikasi, yaitu Random Forest, Support Vector Machine (SVM), dan XGBoost. Evaluasi dilakukan menggunakan data uji untuk mengetahui kemampuan masing-masing algoritma dalam mengklasifikasikan data mahasiswa berdasarkan atribut akademik maupun sosial ekonomi. Selain itu, model terbaik diimplementasikan ke dalam aplikasi berbasis Streamlit sehingga proses prediksi dapat dilakukan secara interaktif oleh pengguna.

3.5.1 Analisis Performa Model

Berdasarkan hasil pengujian, algoritma Random Forest memperoleh nilai accuracy sebesar 73,33%, lebih tinggi dibandingkan Support Vector Machine (70,00%) dan XGBoost (68,33%). Hasil tersebut menunjukkan bahwa Random Forest memiliki kemampuan yang lebih baik dalam mengenali pola hubungan antar atribut pada dataset penerima beasiswa. Kemampuan ini diperoleh karena Random Forest membangun banyak pohon keputusan (decision tree) dan menggabungkan hasil prediksi setiap pohon sehingga mampu menghasilkan prediksi yang lebih stabil dan mengurangi risiko overfitting.

Selain accuracy, nilai Precision, Recall, dan F1-Score pada Random Forest juga menunjukkan performa yang lebih baik dibandingkan dua algoritma lainnya. Hal ini menunjukkan bahwa model tidak hanya mampu menghasilkan prediksi yang akurat, tetapi juga cukup baik dalam mengidentifikasi mahasiswa yang benar-benar layak menerima beasiswa. Berdasarkan hasil evaluasi tersebut, Random Forest dipilih sebagai model utama yang diimplementasikan pada aplikasi prediksi kelayakan penerima beasiswa.

3.5.2 Analisis Faktor yang Mempengaruhi Prediksi

Interpretasi model dilakukan menggunakan metode SHAP (SHapley Additive Explanations) untuk mengetahui kontribusi setiap atribut terhadap hasil prediksi. Berdasarkan visualisasi SHAP Summary Plot, atribut IPK memberikan pengaruh paling besar dalam menentukan kelayakan penerima beasiswa. Hal ini menunjukkan bahwa prestasi akademik masih menjadi faktor utama yang dipertimbangkan oleh model dalam proses klasifikasi.

Selain IPK, atribut Penghasilan Orang Tua, Jumlah Tanggungan Keluarga, dan Prestasi juga memberikan kontribusi yang cukup besar terhadap hasil prediksi. Sementara itu, atribut seperti Jenis Kelamin dan Status Rumah memiliki pengaruh yang relatif lebih kecil

dibandingkan atribut lainnya. Hasil interpretasi tersebut menunjukkan bahwa model mampu mempertimbangkan aspek akademik dan kondisi sosial ekonomi secara bersamaan sehingga keputusan yang dihasilkan menjadi lebih objektif dan mudah dipahami.

3.5.3 Analisis Implementasi Aplikasi

Model Random Forest yang telah dipilih kemudian diimplementasikan ke dalam aplikasi berbasis Streamlit sebagai media pendukung proses seleksi penerima beasiswa. Aplikasi menyediakan beberapa fitur utama, yaitu Dashboard EDA, Model Demo, Evaluasi Model, Interpretasi Hasil, dan Dokumentasi. Seluruh fitur tersebut dirancang agar pengguna dapat memahami proses analisis data, melakukan prediksi, mengevaluasi performa model, hingga memperoleh penjelasan mengenai faktor-faktor yang memengaruhi hasil prediksi.

Implementasi aplikasi menunjukkan bahwa proses prediksi dapat dilakukan secara otomatis hanya dengan memasukkan data mahasiswa sesuai atribut yang tersedia. Hasil prediksi ditampilkan secara langsung beserta tingkat probabilitas model, sehingga aplikasi dapat dimanfaatkan sebagai sistem pendukung keputusan dalam proses seleksi beasiswa. Dengan adanya aplikasi ini, proses seleksi diharapkan menjadi lebih cepat, konsisten, dan objektif dibandingkan proses penilaian yang dilakukan secara manual.

BAB IV

KESIMPULAN DAN REKOMENDASI

4.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, penerapan Machine Learning dapat digunakan untuk membantu proses klasifikasi kelayakan penerima beasiswa berdasarkan data akademik dan sosial ekonomi mahasiswa. Penelitian ini memanfaatkan tiga algoritma klasifikasi, yaitu Random Forest, Support Vector Machine (SVM), dan XGBoost. Ketiga algoritma tersebut dibandingkan untuk mengetahui model yang memiliki performa terbaik dalam melakukan prediksi. Hasil penelitian menunjukkan bahwa pendekatan Machine Learning mampu mendukung proses seleksi beasiswa secara lebih objektif dan berbasis data.

Berdasarkan hasil evaluasi, algoritma Random Forest memperoleh nilai accuracy sebesar 73,33%, lebih tinggi dibandingkan Support Vector Machine (70,00%) dan XGBoost (68,33%). Selain memiliki nilai accuracy tertinggi, Random Forest juga menunjukkan performa yang baik berdasarkan metrik Precision, Recall, dan F1-Score. Oleh karena itu, algoritma Random Forest dipilih sebagai model utama yang digunakan dalam aplikasi prediksi kelayakan penerima beasiswa. Hasil ini menunjukkan bahwa Random Forest paling sesuai untuk diterapkan pada dataset yang digunakan dalam penelitian.

Model terbaik kemudian diimplementasikan ke dalam aplikasi berbasis Streamlit yang mampu melakukan prediksi secara otomatis berdasarkan data yang dimasukkan pengguna. Aplikasi juga dilengkapi dengan fitur evaluasi model, interpretasi menggunakan SHAP, serta dokumentasi pengembangan sistem sehingga pengguna dapat memahami proses prediksi yang dilakukan. Kehadiran aplikasi ini diharapkan dapat membantu proses seleksi beasiswa menjadi lebih cepat, efisien, dan objektif. Selain itu, sistem yang dikembangkan dapat dijadikan sebagai pendukung keputusan dalam proses penentuan penerima beasiswa.

4.2 Rekomendasi

Beberapa rekomendasi yang dapat diberikan untuk pengembangan penelitian selanjutnya adalah sebagai berikut.

1. Menambah jumlah dan variasi dataset agar model dapat mempelajari pola data yang lebih beragam sehingga menghasilkan tingkat akurasi yang lebih baik.
2. Mencoba algoritma Machine Learning lainnya, seperti LightGBM, CatBoost, atau Neural Network untuk membandingkan performa model dalam melakukan klasifikasi kelayakan penerima beasiswa.
3. Mengembangkan aplikasi dengan menambahkan fitur manajemen data penerima beasiswa, autentikasi pengguna, serta integrasi dengan basis data sehingga dapat digunakan secara langsung pada lingkungan institusi pendidikan.

DAFTAR PUSTAKA

- Amalia Maresti, F., Mustika Anugraheni, G., Hargiyanto, R. A., & Mustaqim, K. (2024). PENERAPAN EXPLORATORY DATA ANALYSIS (EDA) DAN ANALISIS RECENCY, FREQUENCY, AND MONETARY (RFM) UNTUK SEGMENTASI PELANGGAN E-COMMERCE. *Competitive*, 19(1), 14–25. <https://doi.org/10.36618/competitive.v19i1.4059>
- Ardhi Baskara, A., Maharani Piranti, N., & Fahrury Romdendine, M. (2025). FRAMEWORK DATA MINING: SEBUAH SURVEI. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 9(3), 4886–4895. <https://doi.org/10.36040/jati.v9i3.13803>
- Eldo, H., Ayuliana, A., Suryadi, D., Chrisnawati, G., & Judijanto, L. (2024). Penggunaan Algoritma Support Vector Machine (SVM) Untuk Deteksi Penipuan pada Transaksi Online. *Jurnal Minfo Polgan*, 13(2), 1627–1632. <https://doi.org/10.33395/jmp.v13i2.14186>
- Firmansyah, M., Rudiyat, A. A., Purnama, R., Utomo, H. P., & Firmansyah, H. S. (n.d.). *Penerapan Algoritma Xgboost dan Random Forest dalam Prediksi Uraian Resiko Proyek Pada Dinas XYZ*. 20(2).
- Laila Sari, S., Rahmat, B., & Kartini, K. (2026). PENERAPAN ALGORITMA GRID SEARCH UNTUK MEMPREDIKSI CUSTOMER CHURN PADA BANK MENGGUNAKAN PERBANDINGAN OPTIMASI DECISION TREE DAN RANDOM FOREST. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 10(1), 908–913. <https://doi.org/10.36040/jati.v10i1.16819>
- Raihani, K., & Dwitama, F. (2025). Implementasi Visualisasi Data Interaktif pada Produk Skincare dan Ulasan Konsumen Menggunakan Metode CRISP-DM. *Jurnal Minfo Polgan*, 14(2), 2805–2815. <https://doi.org/10.33395/jmp.v14i2.15531>
- Rustiyana, R., Judijanto, L., Mahendra, G. S., Kamil, Z. A., Purba, D. N., Sutoyo, M. N., Hendrayana, I. G., Pasrun, Y. P., & Prayudani, S. (2025). *Data Mining: Algoritma dan Penerapannya*. PT. Sonpedia Publishing Indonesia.
- Trisnawan, A. B., & Susilawati, T. (2025). Pemanfaatan Machine Learning untuk Peningkatan Akurasi Sistem Pendukung Keputusan Prediktif. *JURNAL UNITEK*, 18(2), 303–312. <https://doi.org/10.52072/unitek.v18i2.1702>